KBO 타자는 정말 '거포형·준족형·교타형' 세 유형으로 나뉘는가

기록실 3인방 · 10101 홍길동 · 10102 김영희 · 10103 이철수

당곡고등학교 데이터 과학 팀 프로젝트 · 2026

선생님이 만든 가상 팀의 샘플 · 데이터와 수치는 실제 계산값

저장소

1. 서론

연구 질문: KBO 타자는 정말 세 유형으로 나뉘는가

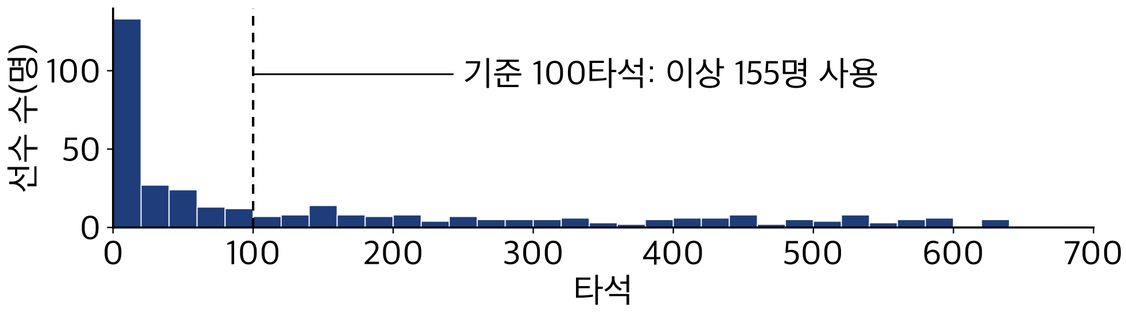
- 야구 중계에서 자주 듣는 "거포", "준족", "교타자"라는 말
- 이 말이 기록에서 나온 것인지, 해설자의 인상에서 나온 것인지 궁금함

이 포스터: 타석당 비율 다섯 개로 묶은 K-평균 결과, 그 해석과 한계

2. 데이터

출처·크기: KBO 공식 기록실 타자 기록(2026 정규 시즌) · **364행 · 25열**

사용한 열	뜻	범위(155명)
타석	비율의 분모, 선수 선별 기준	102~676
홈런율 · 도루율	홈런 · 도루 ÷ 타석	0~0.077 · 0~0.109
볼넷율 · 삼진율	볼넷 · 삼진 ÷ 타석	0.019~0.182 · 0.083~0.364
2루타율	2루타 ÷ 타석	0~0.087



타석 분포(364명): 타석 0인 선수 73명, 중앙값 57

- 타석 7인 선수의 홈런율 0.143이 전체 1위 → 타석 100 이상 **155명**만 사용
- 개수 대신 타석당 비율: 676타석과 100타석 선수를 같은 기준으로 비교
- 표준화: 하지 않으면 삼진율(표준편차 **0.062**)이 거리를 좌우함

3. 방법

수집(364명) → 변수 선택(비율 5개) → 전처리(155명) → 분할(전체·표준화) → 기준선 (k 후보) → 후보 4종 비교 → 선택(K-평균) → 평가(실루엣·엘보우) → 해석(상관·OPS)

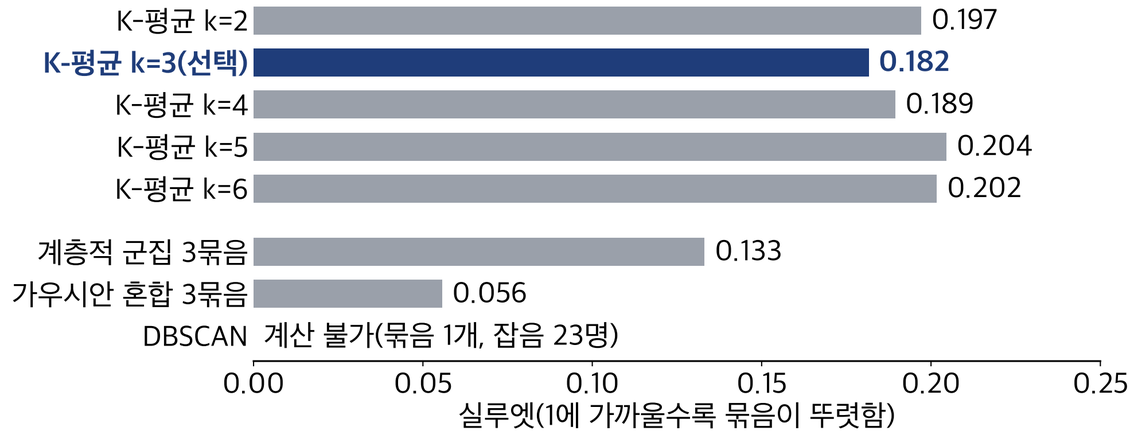
후보 모델(155명 · 표준화 다섯 비율 · 묶음 3개)	실루엣	묶음 크기	K-평균과 겹침
K-평균(k=3, 선택)	**0.182**	**57 · 53 · 45**	**1.00**
계층적 군집(ward)	0.133	74 · 48 · 33	0.77
DBSCAN(반경 1.5, 이웃 10)	계산 불가	132 · 잡음 23	비교 불가
가우시안 혼합(3개)	0.056	71 · 57 · 27	0.43

- K-평균 선택: 묶음별 평균을 그대로 읽어 유형 이름을 붙일 수 있음
- 실루엣도 가장 높지만(0.182) 경계가 흐릿한 값이라 점수만 보지 않음

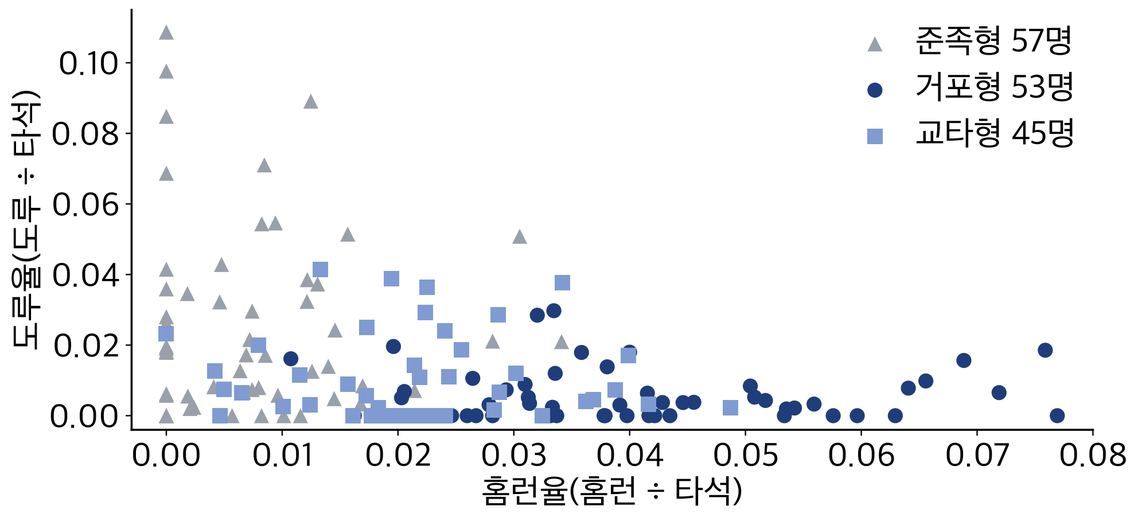
모델	원리	장점	단점	이런 상황에 좋다	우리 데이터 결과
K-평균 (선택)	**가까운 중심에 배정하고 중심을 다시 계산**	**빠르고 평균을 읽기 쉬움**	**k를 미리 정해야 함**	**묶음 수의 근거가 있을 때**	**실루엣 0.182 57 · 53 · 45명**
계층적 군집 (비교 1)	가까운 묶음끼리 차례로 합침	k를 나중에 정할 수 있음	데이터가 많으면 느림	묶음 수를 정하기 어려울 때	실루엣 0.133 겹침 0.77
DBSCAN (비교 2)	촘촘한 곳을 잇고 드문 점은 잡음으로	묶음 수를 정하지 않아도 됨	반경에 따라 결과가 크게 바뀜	묶음 모양이 불규칙할 때	묶음 1개 (132명) 잡음 23명

- **실루엣:** 자기 묶음과 가깝고 다른 묶음과 먼 정도(1에 가까울수록 뚜렷함)
- **엘보우:** 군집 내 제곱합이 줄어드는 폭이 갑자기 작아지는 k를 찾음

4. 결과



k=3(0.182)은 k 후보 다섯 개 가운데 가장 낮고, 묶음 3개에서는 방법 네 가지 가운데 가장 높음



유형별 홈런율과 도루율(155명) · 다섯 비율 가운데 두 개만 그린 그림

0.182
실루엣(K-평균 k=3)

155명
분석 대상(타석 100 이상)

3개
유형(57 · 53 · 45명)

5. 해석과 결론

- **홈런 많으면 삼진도 많지만, 잘 치는 거포는 삼진이 적음**
  홈런율-삼진율 상관 **0.337** · 거포형 안 삼진율-OPS 상관 **-0.415** · 홈런 1위 김도영 삼진율 0.174(평균 0.200)
- **준족형 대부분은 빠른 선수가 아니라 삼진이 적은 선수**
  준족형 도루 중앙값 **3개** · 도루 상위 5명이 전체 도루의 **25.2%**
- **유형은 실력 순서가 아니라 치는 방식의 차이**
  유형 사이 평균 OPS 차이 **0.116** · 거포형 안 오스틴 1.062, 김영웅 0.496
- **타율·OPS 제외:** 넣으면 묶음이 OPS 0.841 · 0.704 · 0.645 순서로 나뉨

세 유형으로 깔끔하게 나뉘지 않음. 거포 특징은 분명, 준족은 소수 개인, 유형은 실력이 아닌 방식의 차이

6. 한계와 향후 연구

- k=3은 실루엣 최저(k=5는 **0.204**), 근거는 해석의 편리함뿐
- 최소 타석 50(196명)이면 준족형이 **11명**으로 줄고 교타형의 특징이 사라짐
- 2026년 한 시즌 기록만 사용, 그래프는 다섯 비율 가운데 두 개만 보여 줌
- **오용 주의:** 이 유형으로 선수 가치를 매기면 안 됨(일부러 뺀 '잘하는 정도'를 덧씌우게 됨)
- **더 해 볼 것:** 2024·2025 시즌을 더해 같은 선수가 해마다 같은 유형인지 확인, 투수 기록에 적용
- **교과·진로:** 체육·수학(표준화)·정보 · 스포츠 데이터 분석가, 구단 전력 분석원

데이터: KBO 공식 기록실(한국야구위원회), 2026 정규시즌 타자 기록 및 선수 등록 명단, www.koreabaseball.com/Record/ , 2026-10-15 접근 · 비상업 교육 목적 사용

모든 수치는 code/check.py로 다시 계산 가능 · 참고: 데이터 출처·소프트웨어는 저장소 README 참고문헌

저장소 github.com/greatsong/ds-sample-3-clustering · 앱 greatsong.github.io/ds-sample-3-clustering

앱